



UNIVERSIDAD POLITÉCNICA DE VICTORIA

REPORTE DE ACTIVIDADES DEL PROYECTO

**MARCADO DE AGUA DIGITAL PROFUNDO Y ROBUSTO EN
SEÑALES DE AUDIO**

QUE PRESENTA

OSVALDO FABIAN RAMIRO BALBOA

**EN CUMPLIMIENTO DE LA ESTADÍA TSU EN
DESARROLLO DE SOFTWARE MULTIPLATAFORMA**

**ASESOR INSTITUCIONAL
DR. SAID POLANCO MARTAGÓN**

**UNIDAD ECONÓMICA RECEPTORA:
CINVESTAV UNIDAD TAMAULIPAS**

**ASESOR DE LA UNIDAD ECONÓMICA
DR. JOSE JUAN GARCIA HERNANDEZ**

Ciudad Victoria, Tamaulipas, Agosto de 2026.



Formato de autorización para exposición de Estadía de Técnico Superior Universitario

Fecha y lugar en que se emite: **Ciudad Victoria, Tamaulipas, a 31 de Julio de 2026**

Nombre completo del estudiante: **Osvaldo Fabian Ramiro Balboa**

Matrícula: **2430098**

Programa Académico: **Desarrollo de Software Multiplataforma**

Por medio del presente, se le informa que tras realizar su Estadía en la empresa **CINVESTAV Unidad Tamaulipas** llevando a cabo el proyecto: **Marcado de agua digital profundo y robusto en señales de audio**, durante el periodo comprendido **Mayo-Agosto 2026** logrando una ponderación de ____ (60% posibles) para el criterio de reporte; por lo tanto, se otorga la oportunidad de exponer el trabajo realizado por medio de un informe ejecutivo programado para el día **12** del mes de **Agosto** del año en curso en un horario de **10:00 hrs** en modalidad **Presencial en la Oficina I-XXX69**.

Sin otro particular, se le recomienda estar disponible para iniciar su exposición 10 minutos antes de la indicación oficial.

Atentamente

Dr. Said Polanco Martagón
Asesor institucional



Control sumativo de Estadía para Técnico Superior Universitario

Criterio	Valor / Ponderación	Calificación
Reporte	60%	
Exposición	40%	
Calificación final		

Datos de la evaluación sumativa

Fecha: **12 / Agosto / 2026**

Dr. Said Polanco Martagón
Asesor institucional

Resumen

El resumen es una representación condensada del contenido del documento. Su propósito es dar al lector un relato de las características principales del reporte. Su redacción es en tercera persona, en tiempo pasado, con escritura continua y sin tablas o imágenes. La extensión sugerida es no mayor a media página. Debe cumplir con las siguientes características:

- Se hace mención del nombre del proyecto como parte de la Estadía, el nombre de la unidad económica y su dirección completa.
- Se menciona el objetivo, meta, actividad o responsabilidad principal que se abordó.
- Se describe detalladamente la metodología desarrollada; tales como herramientas, materiales, equipos, cursos, softwares y conocimientos adquiridos en la universidad utilizados para alcanzar los objetivos empleados.
- Se describen detalladamente los resultados más importantes obtenidos.
- Se termina presentando conclusiones del trabajo.

Abstract

Add your abstract here...

Contenido temático

Resumen	iii
Abstract	iv
1 Introducción	1
1.1 Antecedentes	2
1.1.1 Antecedentes de la Empresa	3
1.1.2 Estado del Arte	4
1.1.3 Comparativa de Trabajos Relacionados	6
1.2 Definición del Problema	8
1.3 Objetivos	9
1.3.1 Objetivo General	9
1.3.2 Objetivos Específicos	10
1.4 Justificación	10
1.5 Alcances y Limitaciones	11
1.5.1 Alcances	11
1.5.2 Limitaciones	11
2 Marco Teórico	13
2.1 Mercado de Agua Digital	13
2.1.1 Arquitectura General de un Sistema de Mercado de Agua	13
2.1.2 Propiedades Fundamentales y el Triángulo de Compromiso	14
2.1.3 Clasificación de los Métodos de Mercado de Agua en Audio	14
2.2 Procesamiento Digital de Audio	15
2.2.1 Muestreo y el Teorema de Nyquist-Shannon	15
2.2.2 Transformada Discreta de Fourier (DFT)	16
2.2.3 Transformada de Fourier de Tiempo Corto (STFT) y el Espectrograma	16
2.2.4 Ventanas de Análisis y el Criterio COLA	17
2.3 Enmascaramiento Psicoacústico	17
2.3.1 El Sistema Auditivo Humano y la Curva de Umbral Absoluto	18
2.3.2 Enmascaramiento en Frecuencia y Enmascaramiento Temporal	18
2.3.3 Bandas Críticas y la Escala Bark	19
2.4 Aprendizaje Profundo (Deep Learning)	19
2.4.1 El Perceptrón y la Neurona Artificial	19

2.4.2	Entrenamiento: Descenso de Gradiente y Retropropagación	20
2.4.3	Redes Neuronales Convolucionales (CNN)	20
2.4.4	Autoencoders	21
2.4.5	Arquitectura U-Net	21
2.4.6	Redes Neuronales Invertibles (INN)	22
2.5	Función de Pérdida en Sistemas de Marcado de Agua Profundo	22
2.6	Métricas de Evaluación	23
2.6.1	Relación Señal-Ruido (SNR)	23
2.6.2	Tasa de Error de Bit (BER)	24
2.6.3	Grado de Distorsión Objetiva (ODG) y PEAQ	24
2.6.4	Precisión de Detección (para sistemas de detección binaria)	24
3	Metodología	25
3.1	Etapa 1: Segmentación del Audio (Preprocesamiento)	25
3.2	Etapa 2: Procesamiento por Bloques (Framing) y Solapamiento (Overlap)	25
3.3	Etapa 3: Diseño e Implementación de la Red Neuronal Profunda	26
4	Resultados	28
5	Conclusiones	29
	Bibliografía	30
	Anexos	31

1 Introducción

La proliferación de plataformas de distribución de contenido digital y la democratización de las herramientas de edición multimedia han transformado radicalmente el panorama de la propiedad intelectual en el siglo XXI. En este contexto, el marcado de agua digital (*digital watermarking*) se ha consolidado como una de las técnicas más relevantes para la protección y autenticación de contenidos multimedia, incluyendo imágenes, vídeo y señales de audio [1]. A diferencia del cifrado convencional, que protege el contenido durante su transmisión pero lo hace accesible una vez descifrado, el marcado de agua integra la información de protección directamente en el contenido mismo, de modo que dicha información permanece ligada al archivo independientemente de los procesos de copia o distribución a los que sea sometido.

En el dominio específico de las señales de audio, el marcado de agua consiste en la inserción de un mensaje binario, denominado marca de agua (*watermark*), dentro de una señal anfitriona (*host signal*) de manera imperceptible para el sistema auditivo humano (HAS, por sus siglas en inglés). Esta incrustación debe resistir diversas manipulaciones que la señal puede sufrir durante su ciclo de vida normal, tales como compresión con pérdida (formato MP3 o AAC), conversión entre formatos, remuestreo, ecualización y adición de ruido ambiental [2]. La capacidad de un sistema de marcado de agua para sobrevivir a estas transformaciones es lo que se denomina *robustez*, y representa uno de los desafíos técnicos más complejos en el área.

Durante las últimas dos décadas, las técnicas de marcado de agua para audio han evolucionado significativamente. Los métodos clásicos, basados en modificaciones en el dominio del tiempo o en el dominio de la frecuencia mediante transformadas matemáticas como la Transformada Discreta de Wavelet (DWT) o la Transformada de Fourier (DFT), ofrecían soluciones robustas para escenarios controlados. Sin embargo, su diseño manual de características (*hand-crafted features*) los hace inherentemente limitados frente a ataques adaptativos o combinaciones complejas de procesamiento de señales [3]. El surgimiento y la madurez de las técnicas de aprendizaje profundo (*Deep Learning*) ha abierto una nueva era en este campo, en la que los sistemas aprenden de forma automática, a partir de datos, las representaciones óptimas para esconder y recuperar la información oculta.

El presente proyecto, desarrollado en el Centro de Investigación y de Estudios Avanzados del Instituto Politécnico Nacional (CINVESTAV) Unidad Tamaulipas, bajo la dirección del Dr. Jose Juan Garcia Hernandez, propone el desarrollo de un sistema de marcado de agua digital profundo y robusto en señales de audio. El sistema está fundamentado en arquitecturas de redes neuronales

profundas, específicamente en modelos tipo Autoencoder y U-Net, que operan principalmente en el dominio tiempo-frecuencia a través de la Transformada de Fourier de Tiempo Corto (STFT). El objetivo central es lograr un equilibrio óptimo entre imperceptibilidad acústica y resistencia a ataques de procesamiento de señales no intencionales, tales como la compresión MP3 con diferentes tasas de bits, la adición de ruido blanco gaussiano y el filtrado pasa-bajos.

Este trabajo adquiere especial relevancia ante el auge de las tecnologías generativas basadas en inteligencia artificial, como los modelos de síntesis de voz (*text-to-speech*) y los modelos de clonación de voz (*voice cloning*), que facilitan la creación y distribución de contenido de audio falso o no autorizado. En este escenario, un sistema robusto de marcado de agua profundo no solo tiene aplicaciones en la gestión de derechos digitales (DRM), sino también en la autenticación forense de contenidos y en la lucha activa contra la desinformación generada por inteligencia artificial.

1.1 Antecedentes

La historia del marcado de agua digital en audio puede dividirse en tres grandes etapas tecnológicas. La primera etapa, que abarca aproximadamente desde mediados de la década de 1990 hasta principios de los 2000, se caracterizó por el desarrollo de técnicas en el dominio del tiempo, como la modificación del bit menos significativo (LSB, *Least Significant Bit*). En este paradigma, la marca de agua se inserta alterando los bits de menor peso de las muestras de audio, lo que resulta en una baja distorsión perceptible, pero también en una escasa robustez ante cualquier tipo de procesamiento digital [2].

La segunda etapa corresponde al auge de los métodos en el dominio de la frecuencia, que aprovechan la estructura espectral de la señal de audio para esconder la marca en regiones donde el sistema auditivo humano es menos sensible. Técnicas como la expansión de espectro (*spread spectrum*), propuesta por Boney et al. [3], o el uso de la Transformada Discreta de Coseno (DCT) y la Transformada Discreta de Wavelet (DWT), permitieron mejorar considerablemente la robustez frente a compresión y filtrado. Paralelamente, el desarrollo de modelos psicoacústicos basados en el estándar MPEG (como el modelo psicoacústico de la norma ISO/IEC 11172-3) permitió identificar con mayor precisión las regiones de enmascaramiento, es decir, aquellas frecuencias y rangos temporales donde la energía añadida por la marca de agua resulta inaudible para el oyente humano.

La tercera y más reciente etapa corresponde a la aplicación del aprendizaje profundo al problema

del marcado de agua. El trabajo seminal de Zhu et al. [4], denominado *HiDDeN* (*Hiding Data with Deep Networks*), demostró por primera vez la viabilidad de un sistema de marcado de agua de extremo a extremo (*end-to-end*) para imágenes, en el que tanto el incrustador (*encoder*) como el extractor (*decoder*) son redes neuronales entrenadas conjuntamente, junto con una red adversaria que simula los ataques. Este paradigma fue posteriormente adaptado y ampliado al dominio del audio, dando lugar a una nueva generación de sistemas que superan en robustez e imperceptibilidad a los métodos tradicionales.

1.1.1 Antecedentes de la Empresa

El Centro de Investigación y de Estudios Avanzados del Instituto Politécnico Nacional (CINVESTAV) es una institución pública de investigación científica y desarrollo tecnológico, adscrita al Instituto Politécnico Nacional (IPN). Fundado en 1961, el CINVESTAV es reconocido a nivel nacional e internacional como uno de los centros de investigación más importantes de América Latina, con contribuciones significativas en matemáticas, física, biología, ingeniería y ciencias computacionales.

Ubicación. La Unidad Tamaulipas del CINVESTAV se encuentra ubicada en Ciudad Victoria, Tamaulipas, México, siendo una de las unidades regionales del CINVESTAV establecidas para fortalecer el desarrollo científico y tecnológico en el interior de la República.

Giro. La Unidad Tamaulipas se dedica a la investigación científica básica y aplicada, así como a la formación de recursos humanos de posgrado de alto nivel (maestría y doctorado) en áreas de tecnologías de la información, procesamiento de señales y sistemas inteligentes.

Misión. Realizar investigación científica y tecnológica de vanguardia, así como formar investigadores y técnicos de excelencia que contribuyan al desarrollo científico, tecnológico y social de México, generando conocimiento de frontera con impacto nacional e internacional.

Visión. Consolidarse como un centro de investigación de clase mundial, reconocido por la calidad e impacto de sus contribuciones científicas en ciencias e ingeniería, y por la formación de recursos humanos capaces de enfrentar los retos tecnológicos del siglo XXI.

Infraestructura. La Unidad Tamaulipas cuenta con laboratorios especializados en procesamiento de señales y sistemas inteligentes, equipados con estaciones de trabajo de alto rendimiento y unidades de procesamiento gráfico (GPU) para el entrenamiento de modelos de aprendizaje profundo. El laboratorio donde se desarrolla el presente proyecto dispone de acceso a

servidores con GPU de alto rendimiento, infraestructura fundamental para el entrenamiento de redes neuronales profundas con grandes conjuntos de datos de audio. Adicionalmente, la unidad cuenta con acceso a repositorios especializados de datos y a una red académica de colaboración con otras instituciones nacionales e internacionales.

El Dr. Jose Juan Garcia Hernandez, investigador titular de la Unidad Tamaulipas, lidera líneas de investigación en seguridad de la información y procesamiento de señales multimedia, en las cuales se enmarca el presente proyecto de estadía. Su experiencia en el área garantiza la dirección metodológica y científica del trabajo, asegurando que los resultados obtenidos sean pertinentes y de calidad académica.

1.1.2 Estado del Arte

El campo del marcado de agua profundo en audio ha experimentado un crecimiento exponencial en los últimos cinco años. A continuación, se presenta un análisis detallado de las contribuciones más relevantes, sus metodologías, sus resultados cuantitativos y sus limitaciones, a fin de contextualizar la propuesta del presente trabajo.

HiDDeN (Zhu et al., 2018). El modelo *HiDDeN* [4] fue el punto de inflexión para el marcado de agua basado en redes profundas. Su arquitectura consiste en un codificador CNN que toma la imagen anfitriona y el mensaje binario como entrada, produciendo una imagen marcada; un bloque de ruido (*noise layer*) que simula ataques como la compresión JPEG o la adición de ruido; y un decodificador CNN que recupera el mensaje. Aunque fue concebido para imágenes, su paradigma de entrenamiento adversarial y su formulación de pérdida combinada (reconstrucción + decodificación) establecieron el estándar para todos los sistemas posteriores, incluyendo los de audio.

WavMark (Chen et al., 2023). *WavMark* [5] adaptó el paradigma de *HiDDeN* al dominio del audio mediante el uso de Redes Neuronales Invertibles (INN, *Invertible Neural Networks*). La propiedad de invertibilidad garantiza que la transformación del codificador sea matemáticamente reversible, lo que asegura una alta fidelidad en la reconstrucción del audio original y minimiza la distorsión introducida. El sistema reporta una capacidad de hasta 32 bits por segundo de audio y una Tasa de Error de Bit (BER) menor al 1% bajo ataques de ruido gaussiano. Sin embargo, su principal limitación radica en la sensibilidad a variaciones de fase, que son introducidas por ataques como el re-muestreo o la compresión MP3 con tasas de bits muy bajas. Esto se debe a que las INN operan en el dominio del tiempo y no explotan directamente las propiedades de

enmascaramiento psicoacústico.

DeAR (Liu et al., 2023). El sistema *DeAR* (*Deep-learning-based Audio Re-recording Resilient Watermarking*) [6] se diseñó específicamente para enfrentar uno de los ataques más complejos en el dominio del audio: el re-grabado (*re-recording attack*), en el que el audio se reproduce a través de altavoces físicos y es capturado nuevamente por un micrófono en un entorno acústico real. Este tipo de ataque introduce reverberación, ruido ambiental y distorsiones no lineales del altavoz, lo que resulta en una degradación significativa de cualquier marca de agua convencional. *DeAR* opera en el dominio del espectrograma (representación 2D tiempo-frecuencia) y emplea una red de simulación acústica que modela el entorno de re-grabado durante el entrenamiento. Su desventaja principal es la alta carga computacional tanto en el entrenamiento como en la inferencia, lo que limita su aplicabilidad en escenarios de recursos restringidos.

AudioSeal (San Roman et al., 2024). *AudioSeal* [7], desarrollado por Meta AI, representa el estado del arte más reciente en detección proactiva de clonación de voz. A diferencia de los sistemas tradicionales que buscan recuperar un mensaje binario, *AudioSeal* está diseñado para detectar si un fragmento de audio (incluso de pocos segundos) ha sido marcado o no, lo que permite identificar audios generados por modelos de IA. Su arquitectura se basa en una red generativa que incrusta la marca directamente en el dominio de la forma de onda (*waveform domain*), junto con un detector localizado que puede identificar la marca en segmentos cortos. Reporta una alta robustez frente a edición de audio, compresión MP3 y adición de ruido. Su principal limitación es que está optimizado para la tarea de detección binaria (marcado/no marcado) y no para la recuperación de mensajes de alta capacidad.

SilentCipher (Singh et al., 2024). *SilentCipher* [8] es actualmente uno de los sistemas con mayor imperceptibilidad reportada (*SOTA* en métricas perceptuales). Su contribución central es la integración de un modelo psicoacústico diferenciable durante el entrenamiento, que calcula los umbrales de enmascaramiento de la señal en tiempo real y restringe la energía de la marca de agua a permanecer siempre por debajo de estos umbrales. Esto garantiza, de forma matemáticamente fundamentada, que la marca sea inaudible. El sistema opera en el dominio de la frecuencia y reporta valores de SNR superiores a 38 dB y BER cercana a 0% bajo ataques estándar. Su principal desafío es la complejidad del modelo psicoacústico integrado, que requiere un ajuste cuidadoso de hiperparámetros para cada tipo de señal de audio.

IDEAW (Li et al., 2024). El sistema *IDEAW* (*Robust Neural Audio Watermarking with Invertible Dual-Embedding*) [9] introduce una estrategia de doble incrustación invertible, en la

que la marca de agua se inserta de forma redundante en dos representaciones complementarias de la señal: la forma de onda temporal y el espectrograma. Esta redundancia mejora significativamente la robustez ante ataques que afectan preferentemente a uno u otro dominio. El sistema fue presentado en EMNLP 2024 y representa uno de los trabajos más recientes en el área, demostrando que la combinación de dominios es una dirección prometedora para el diseño de sistemas robustos.

Con el fin de establecer comparativas objetivas entre sistemas, la comunidad científica ha desarrollado marcos de evaluación estandarizados. *AudioMarkBench* [10] es un *benchmark* reciente que evalúa la robustez de múltiples sistemas de marcado de agua ante una batería de ataques, incluyendo compresión MP3 a diferentes tasas de bits, adición de ruido gaussiano, filtrado pasa-bajos, eco, cambios de velocidad (*time-stretching*) y cambios de tono (*pitch-shifting*). Sus resultados evidencian que ningún sistema actual logra robustez óptima ante todos los tipos de ataques simultáneamente, lo que confirma la relevancia del problema abierto que aborda el presente trabajo.

1.1.3 Comparativa de Trabajos Relacionados

A partir del estudio de los trabajos anteriores, es posible identificar con precisión las principales brechas que la propuesta del presente proyecto busca atender. La Tabla 1 presenta una comparativa cuantitativa y cualitativa de los sistemas más relevantes del estado del arte, incluyendo métricas objetivas de imperceptibilidad (SNR), precisión de extracción (BER) sin ataque y bajo compresión MP3, capacidad de ocultamiento en bits por segundo, y los ataques evaluados en cada trabajo. La propuesta del presente proyecto se incluye como última fila para facilitar la comparación directa.

Del análisis cuantitativo de la Tabla 1 se desprenden las siguientes observaciones que justifican y diferencian la propuesta del presente trabajo:

- **Robustez ante compresión MP3 y preservación de fase:** Los sistemas que operan en el dominio temporal, como *WavMark* [5], reportan una BER de 10–20% bajo compresión MP3 a 128 kbps, lo que los hace poco confiables debido a su sensibilidad a la alteración de fase. La propuesta aborda esto operando en el dominio del espectrograma (STFT), incrustando la marca exclusivamente en las magnitudes de las frecuencias bajas y dejando la fase original completamente inalterada. Esto maximiza la robustez ante compresión y fija un objetivo de $BER < 5\%$ bajo MP3.

Tabla 1: Comparativa cuantitativa y cualitativa de sistemas de marcado de agua profundo en audio. BER = Tasa de Error de Bit; SNR = Relación Señal-Ruido; N/A = No aplica o no reportado; AUC = Área bajo la curva ROC (para sistemas de detección binaria).

Sistema	Año	Dominio de Operación	Cap. (bps)	SNR (dB)	BER sin ataque (%)	BER MP3 128 kbps (%)	Ataques principales evaluados	Diferencia clave vs. propuesta
Boney et al. [3]	1996	Tiempo / Frecuencia	~20	~20	<10	>30	Ruido aditivo, compresión básica	Sin aprendizaje profundo; muy bajo rendimiento ante ataques de compresión modernos
HiDDeN [4]	2018	Imagen (espacial)	N/A	N/A	<1	N/A	JPEG, ruido, recorte espacial	Diseñado para imágenes; adaptación a audio requiere rediseño arquitectónico fundamental
WavMark [5]	2023	Waveform (tiempo)	32	~38	<1	10–20	Ruido gaussiano, compresión MP3, remuestreo	Opera en dominio temporal; sensible a cambios de fase por MP3; BER se eleva significativamente bajo compresión
DeAR [6]	2023	Espectrograma	~16	—	<5	Moderado	Re-grabado físico, ruido ambiental	Especializado en re-grabado físico; poca generalización y alto costo computacional
AudioSeal [7]	2024	Waveform	Detección	>30	AUC >0.95	AUC >0.90	Edición, MP3, ruido, recorte	Solo detección binaria (marcado/no marcado); no recupera mensaje de alta capacidad
Silent Cipher [8]	2024	Frecuencia	48	>38	<2	<5	Ruido, MP3, filtrado, time-stretch	Alta imperceptibilidad, pero requiere modelo psicoacústico diferenciable de alta complejidad computacional
IDEAW [9]	2024	Waveform + Espect.	48	—	<3	<5	Ruido, MP3, time-stretch, pitch-shift	Doble incrustación aumenta robustez multi-dominio pero eleva el costo de inferencia y la complejidad arquitectónica
Propuesta	2025	STFT (Solo magnitudes bajas, Fase intacta)	~32	>30	<2	<5	MP3 (64–128 kbps), ruido gaussiano, filtrado pasa-bajos	Balance robustez-imperceptibilidad con U-Net en dominio espectral; reproducible con GPU de gama media

- **Imperceptibilidad vs. complejidad:** *SilentCipher* [8] logra el mayor SNR reportado (>38 dB) mediante la integración de un modelo psicoacústico diferenciable durante el entrenamiento. Sin embargo, su replicación requiere recursos computacionales especializados y ajuste fino de hiperparámetros. La propuesta alcanza un SNR objetivo de >30 dB mediante la función de pérdida de reconstrucción estándar, siendo reproducible con una GPU de gama media.
- **Generalización de robustez:** A diferencia de *DeAR* [6], cuya robustez se concentra en el escenario específico del re-grabado físico, y de *AudioSeal* [7], que solo ofrece detección binaria, la propuesta busca robustez generalizada ante los ataques no intencionales más frecuentes en flujos de distribución digital: compresión MP3, ruido gaussiano y filtrado pasa-bajos.
- **Capacidad y eficiencia arquitectónica:** Sistemas como *IDEAW* [9] alcanzan mayor capacidad (48 bps) mediante una arquitectura de doble dominio, pero a costa de un alto costo de inferencia. La propuesta adopta ~ 32 bps con una arquitectura U-Net de un solo dominio espectral, representando un mejor equilibrio entre capacidad, robustez y eficiencia computacional para el contexto de aplicación definido.

1.2 Definición del Problema

El problema central que aborda este proyecto puede formularse de manera formal de la siguiente manera. Sea $x \in \mathbb{R}^T$ una señal de audio de longitud T muestras y sea $m \in \{0, 1\}^L$ un mensaje binario de L bits que se desea incrustar en dicha señal. El objetivo de un sistema de marcado de agua es encontrar una función de incrustación $E : \mathbb{R}^T \times \{0, 1\}^L \rightarrow \mathbb{R}^T$ y una función de extracción $D : \mathbb{R}^T \rightarrow \{0, 1\}^L$ tales que se satisfagan simultáneamente las siguientes condiciones:

- **Imperceptibilidad:** La señal marcada $\hat{x} = E(x, m)$ debe ser perceptualmente indistinguible de la señal original x . Formalmente, se requiere que la diferencia $\hat{x} - x$ permanezca por debajo del umbral de enmascaramiento psicoacústico del sistema auditivo humano en todo instante de tiempo.
- **Robustez:** Sea $A(\hat{x})$ la señal resultante de aplicar un ataque de procesamiento A (compresión, ruido, filtrado, etc.) sobre la señal marcada. Se requiere que el extractor sea capaz de recuperar el mensaje con una tasa de error de bit (BER) mínima: $D(A(\hat{x})) \approx m$.
- **Capacidad:** La cantidad de información L que se puede insertar por unidad de tiempo

sin violar la condición de imperceptibilidad debe ser maximizada.

Estas tres condiciones forman un triángulo de compromiso (*trade-off triangle*) intrínsecamente conflictivo [1]: aumentar la capacidad tiende a degradar la imperceptibilidad; aumentar la robustez requiere insertar la marca con mayor energía, lo que también compromete la imperceptibilidad. Resolver este compromiso de forma eficiente es, precisamente, el reto fundamental del área.

En el contexto específico de este trabajo, el problema se agudiza porque los sistemas distribuidos de contenido digital (plataformas de *streaming*, redes sociales, servicios de nube) aplican de forma rutinaria una o más de las siguientes transformaciones a los archivos de audio antes de que lleguen al usuario final: transcodificación a MP3 o AAC con tasas de bits entre 64 y 192 kbps, normalización de volumen, recorte de frecuencias superiores a cierto umbral, y mezcla con otras fuentes de audio. Cada uno de estos procesos puede destruir parcial o totalmente la información oculta en una marca de agua convencional.

El problema que se plantea resolver es, por tanto, el siguiente: *¿Es posible diseñar y entrenar una red neuronal profunda que aprenda automáticamente a incrustar una marca de agua en las frecuencias bajas de la representación espectral (espectrograma) de una señal de audio, preservando intacta la fase original, de tal forma que la marca sobreviva a las transformaciones de procesamiento de señales más comunes en entornos de distribución digital, manteniendo al mismo tiempo una calidad perceptual equivalente a la del audio original?*

La hipótesis de trabajo es afirmativa: al entrenar un modelo de tipo U-Net o Autoencoder convolucional en el dominio del espectrograma STFT para modificar únicamente las magnitudes de baja frecuencia, manteniendo la fase original sin procesar, y con una capa de ruido diferenciable que simule los ataques de interés durante el entrenamiento, la red puede aprender representaciones del mensaje inherentemente robustas a dichas transformaciones, sin necesidad de un diseño manual de características.

1.3 Objetivos

1.3.1 Objetivo General

Desarrollar un sistema de marcado de audio digital basado en redes neuronales profundas, robusto a ataques de procesamiento de señales no intencionales, que garantice un equilibrio entre imperceptibilidad acústica, capacidad de carga y confiabilidad en la extracción de la marca de

agua.

1.3.2 Objetivos Específicos

- Realizar una investigación exhaustiva del estado del arte en técnicas de marcado de agua profundo en audio, identificando las arquitecturas, dominios de operación y estrategias de robustez más efectivas.
- Diseñar e implementar una arquitectura de red neuronal de extremo a extremo (Autoencoder convolucional o U-Net) que opere en el dominio espectral (STFT), integrando una capa diferenciable de simulación de ataques durante el entrenamiento.
- Preprocesar y segmentar un conjunto de datos diverso de señales de audio (voz, música y sonidos ambientales) para generar un conjunto de entrenamiento y evaluación estandarizado.
- Evaluar el rendimiento del sistema mediante métricas objetivas de calidad perceptual (SNR, ODG/PEAQ) y de robustez (BER), comparando los resultados frente a los sistemas del estado del arte reportados en la literatura.
- Analizar el comportamiento del sistema ante diferentes niveles de intensidad de los ataques, con el fin de establecer los límites operativos del prototipo desarrollado.

1.4 Justificación

La relevancia de este proyecto se sustenta en tres dimensiones complementarias. Desde el punto de vista técnico-científico, el marcado de agua profundo en audio es un problema abierto con múltiples brechas sin resolver, tal como lo evidencia el análisis del estado del arte presentado en la sección anterior y el *benchmark AudioMarkBench* [10]. Ningún sistema actual logra robustez simultánea ante todos los tipos de ataques con bajo costo computacional, lo que hace del presente proyecto una contribución pertinente al avance del conocimiento en el área.

Desde el punto de vista de aplicación industrial, la creciente producción de contenido de audio generado por inteligencia artificial —incluyendo *podcasts* sintéticos, audiolibros generados, clonación de voz y música compuesta por IA— crea una demanda urgente de mecanismos de autenticación que permitan rastrear el origen de los contenidos y detectar usos no autorizados. Sistemas como *AudioSeal* de Meta AI [7] ya están siendo considerados para su integración en

plataformas comerciales, lo que demuestra la madurez y la viabilidad comercial de esta línea de investigación.

Finalmente, desde el punto de vista formativo, el desarrollo de este sistema implica la integración de conocimientos de procesamiento digital de señales, aprendizaje profundo, programación en Python y evaluación experimental rigurosa, lo que constituye una experiencia integral para la formación en el área de Desarrollo de Software Multiplataforma con énfasis en inteligencia artificial.

1.5 Alcances y Limitaciones

1.5.1 Alcances

- Desarrollo de un prototipo funcional en Python utilizando librerías de alto nivel como PyTorch, librosa y numpy, con código documentado y reproducible.
- Entrenamiento del modelo con un conjunto de datos diverso que incluya voz, música y sonidos ambientales, utilizando un subconjunto del corpus MUSDB18 o conjuntos de datos de dominio público.
- Evaluación sistemática del sistema bajo ataques de compresión MP3 (a 128 kbps y 64 kbps), ruido blanco gaussiano (SNR de 20 dB y 10 dB) y filtrado pasa-bajos (frecuencia de corte de 8 kHz).
- Comparación cuantitativa de los resultados con los valores reportados por sistemas del estado del arte como *WavMark* [5] y *SilentCipher* [8].

1.5.2 Limitaciones

- El sistema requiere hardware especializado (GPU con soporte CUDA) para un entrenamiento eficiente; el entrenamiento en CPU resulta inviable en tiempos razonables.
- La robustez contra ataques maliciosos diseñados específicamente para burlar la red (ataques adversariales) está fuera del alcance de este proyecto y constituye una línea de trabajo futuro.
- El procesamiento en tiempo real no es un requisito del prototipo y dependerá de la optimización del modelo final en versiones futuras.

- La evaluación se limita a los ataques especificados; la generalización a otros tipos de ataques no evaluados durante el entrenamiento no está garantizada.

2 Marco Teórico

Este capítulo establece los fundamentos teóricos necesarios para comprender el diseño, implementación y evaluación del sistema de marcado de agua profundo propuesto. Se abordan los principios del marcado de agua digital, el procesamiento de señales de audio en el dominio tiempo-frecuencia, los modelos psicoacústicos del sistema auditivo humano y las arquitecturas de aprendizaje profundo empleadas. El nivel de detalle presentado busca ser suficiente para que un lector con conocimientos básicos de ingeniería pueda comprender y, en su caso, replicar el trabajo desarrollado.

2.1 Marcado de Agua Digital

El marcado de agua digital es una rama de la esteganografía que estudia la inserción de información secundaria, denominada marca de agua (*watermark*), en una señal multimedia (imagen, video, audio) de manera que resulte imperceptible para los sentidos humanos pero recuperable mediante algoritmos especializados [1]. A diferencia de la criptografía, que protege el canal de comunicación cifrando el contenido, el marcado de agua protege el contenido en sí mismo: incluso si la señal marcada es distribuida, copiada o transformada, la marca permanece ligada a ella.

2.1.1 Arquitectura General de un Sistema de Marcado de Agua

Un sistema de marcado de agua genérico consta de los siguientes componentes funcionales:

1. **Codificador (Incrustador, *Encoder*):** Recibe la señal original x y el mensaje m , y produce la señal marcada $\hat{x} = E(x, m)$. En sistemas tradicionales, este proceso es una operación determinista (por ejemplo, sumar una pseudoseñal al audio). En sistemas basados en aprendizaje profundo, el codificador es una red neuronal entrenada.
2. **Canal de Ataque:** Representa todas las transformaciones que puede sufrir la señal marcada entre su generación y su verificación. Incluye compresión con pérdida (MP3, AAC), adición de ruido, filtrado, remuestreo, re-grabado y, en escenarios maliciosos, ataques deliberados de borrado de marca (*watermark removal attacks*).
3. **Decodificador (Extractor, *Decoder*):** Recibe la señal potencialmente degradada $\tilde{x} = A(\hat{x})$ y estima el mensaje oculto: $\hat{m} = D(\tilde{x})$. La calidad del extractor se mide por la tasa de error de bit (BER, *Bit Error Rate*).

2.1.2 Propiedades Fundamentales y el Triángulo de Compromiso

Según Cox et al. [1], todo sistema de marcado de agua debe ser diseñado equilibrando tres propiedades fundamentales que forman un *triángulo de compromiso*:

- **Imperceptibilidad (*Imperceptibility*):** La diferencia entre la señal original x y la señal marcada $\hat{x}$ debe ser inaudible para el sistema auditivo humano. Formalmente, la energía de la perturbación $\delta = \hat{x} - x$ debe ser menor que el umbral de enmascaramiento psicoacústico en todo momento.
- **Robustez (*Robustness*):** La marca de agua debe ser recuperable incluso después de que la señal haya sufrido degradaciones o ataques. Se define cuantitativamente como la capacidad de mantener una BER baja bajo un conjunto de ataques predefinidos. Un sistema es *robusto* si $\text{BER}(D(A(\hat{x})), m) < \epsilon$ para un umbral de tolerancia ϵ (típicamente $\epsilon < 0.01$ en la literatura reciente).
- **Capacidad (*Capacity*):** Es la cantidad máxima de información (en bits) que puede incrustarse por unidad de tiempo (generalmente expresada en bits por segundo, bps) sin violar la condición de imperceptibilidad. Se rige por los principios de la teoría de la información: a mayor capacidad, menor robustez potencial.

La relación de compromiso es intrínseca: incrementar la robustez requiere insertar la marca con mayor energía, lo que degrada la imperceptibilidad; aumentar la capacidad requiere transportar más información, lo que también aumenta la energía de la perturbación. El diseño óptimo de un sistema de marcado de agua consiste en encontrar el equilibrio más favorable entre estas tres propiedades para el contexto de aplicación específico.

2.1.3 Clasificación de los Métodos de Marcado de Agua en Audio

Los métodos de marcado de agua en audio pueden clasificarse según el dominio en el que operan:

- **Dominio del tiempo (*time domain*):** La marca se inserta directamente en las muestras de la señal. El método más simple es la modificación del bit menos significativo (LSB). Ofrece alta capacidad pero muy baja robustez.
- **Dominio de la frecuencia (*frequency domain*):** La marca se inserta en los coeficientes espectrales de la señal tras aplicar una transformada (DFT, DCT, DWT). Permite aprovechar propiedades psicoacústicas y ofrece mayor robustez frente a ataques de procesamiento

estándar.

- **Dominio tiempo-frecuencia (*time-frequency domain*):** La marca se inserta en la representación tiempo-frecuencia de la señal (espectrograma STFT). Este enfoque combina las ventajas del análisis espectral con la localización temporal, siendo el adoptado en la mayoría de los sistemas modernos basados en aprendizaje profundo.

2.2 Procesamiento Digital de Audio

El audio digital es una representación discreta de una onda de presión sonora continua. Antes de poder aplicar cualquier algoritmo de marcado de agua, la señal debe entenderse en sus representaciones fundamentales: el dominio del tiempo y el dominio de la frecuencia.

2.2.1 Muestreo y el Teorema de Nyquist-Shannon

El proceso de digitalización de una señal de audio analógica $x_a(t)$ consiste en dos pasos: el muestreo y la cuantificación. El muestreo consiste en tomar el valor de la señal continua a intervalos regulares de tiempo T_s , produciendo la secuencia discreta:

$$x[n] = x_a(n \cdot T_s), \quad n \in \mathbb{Z} \quad (1)$$

donde $f_s = 1/T_s$ es la frecuencia de muestreo (en Hz).

El **Teorema de Nyquist-Shannon** establece que, para reconstruir perfectamente la señal analógica original a partir de sus muestras discretas, la frecuencia de muestreo f_s debe ser estrictamente mayor que el doble de la frecuencia máxima f_{max} contenida en la señal:

$$f_s > 2f_{max} \quad (2)$$

Si esta condición no se cumple, se produce el fenómeno de *aliasing*, en el que componentes de alta frecuencia se superponen sobre frecuencias bajas, distorsionando irreversiblemente la señal. Para audio de alta fidelidad, el oído humano percibe frecuencias hasta aproximadamente 20 kHz, por lo que las frecuencias de muestreo estándar son 44,100 Hz (estándar CD) y 48,000 Hz (estándar para producción audiovisual y radiodifusión).

La cuantificación asigna un valor entero a cada muestra dentro de un rango finito. Para audio de 16 bits, cada muestra toma un valor en el rango $[-32768, 32767]$, lo que proporciona una relación

señal-ruido de cuantificación (SQNR) de aproximadamente $6.02 \times 16 \approx 96.3$ dB, suficiente para la mayoría de aplicaciones de alta fidelidad.

2.2.2 Transformada Discreta de Fourier (DFT)

La Transformada Discreta de Fourier (DFT) descompone una señal discreta en sus componentes de frecuencia. Para una secuencia $x[n]$ de longitud N , la DFT se define como:

$$X[k] = \sum_{n=0}^{N-1} x[n] \cdot e^{-j\frac{2\pi}{N}kn}, \quad k = 0, 1, \dots, N-1 \quad (3)$$

donde $X[k]$ es el coeficiente complejo correspondiente a la frecuencia discreta $f_k = k \cdot f_s/N$. La magnitud $|X[k]|$ representa la amplitud de la componente de frecuencia f_k , y la fase $\angle X[k]$ representa su desplazamiento temporal. La DFT se calcula eficientemente mediante el algoritmo de la Transformada Rápida de Fourier (FFT), con complejidad $\mathcal{O}(N \log N)$ en lugar de los $\mathcal{O}(N^2)$ de la DFT directa.

2.2.3 Transformada de Fourier de Tiempo Corto (STFT) y el Espectrograma

El audio es una señal no estacionaria: sus propiedades estadísticas y espectrales cambian con el tiempo (por ejemplo, una melodía pasa de una nota a otra, o un hablante cambia de fonema). La DFT global de toda la señal pierde la información sobre *cuándo* ocurre cada componente de frecuencia. Para obtener una representación tiempo-frecuencia, se utiliza la **Transformada de Fourier de Tiempo Corto (STFT)**.

La STFT divide la señal en bloques o tramas cortas (*frames*) mediante una función de ventana $w[n]$, y calcula la DFT de cada trama por separado. Formalmente:

$$X(m, k) = \sum_{n=0}^{N-1} x[n + mH] \cdot w[n] \cdot e^{-j\frac{2\pi}{N}kn} \quad (4)$$

donde:

- m es el índice de trama (posición temporal),
- H es el tamaño del salto (*hop size*, en muestras), que determina el solapamiento entre tramas consecutivas,
- N es el tamaño de la ventana (*window size*), que determina la resolución en frecuencia

$$(\Delta f = f_s/N),$$

- $w[n]$ es la función de ventana (típicamente Hann o Hamming), que reduce los efectos de borde al forzar suavemente a cero los bordes de cada trama.

El resultado es una matriz compleja $X \in \mathbb{C}^{(N/2+1) \times M}$, donde $M = \lfloor (T-N)/H \rfloor + 1$ es el número de tramas. El **espectrograma** es la representación de la energía (magnitud al cuadrado) en el plano tiempo-frecuencia:

$$S(m, k) = |X(m, k)|^2 \quad (5)$$

En el contexto del marcado de agua profundo, el espectrograma o la magnitud $|X(m, k)|$ son usados como entrada de las redes neuronales, dado que tienen una estructura similar a la de una imagen en escala de grises: dos dimensiones (tiempo y frecuencia) con valores positivos que pueden ser procesados eficientemente por redes convolucionales. La Transformada Inversa de Fourier de Tiempo Corto (ISTFT) permite reconstruir la señal de audio en el dominio del tiempo a partir de la representación modificada en el dominio tiempo-frecuencia.

2.2.4 Ventanas de Análisis y el Criterio COLA

La elección de la función de ventana $w[n]$ y del tamaño de salto H no es arbitraria. Para garantizar una reconstrucción perfecta de la señal mediante el método de *Overlap-Add* (OLA), debe cumplirse el criterio de **Constant Overlap-Add (COLA)**:

$$\sum_{m=-\infty}^{\infty} w[n - mH] = C, \quad \forall n \quad (6)$$

donde C es una constante. La ventana de Hann con solapamiento del 50% ($H = N/2$) satisface este criterio, lo que significa que la suma de todas las ventanas desplazadas es constante, garantizando que no haya artefactos en la reconstrucción de la señal de audio marcada.

2.3 Enmascaramiento Psicoacústico

El sistema auditivo humano (HAS) no percibe todos los sonidos con igual sensibilidad. Esta característica, estudiada por la psicoacústica, puede explotarse en el marcado de agua para insertar la marca de forma imperceptible: si la energía de la perturbación introducida por la marca permanece por debajo del umbral de percepción auditiva en cada frecuencia y en cada instante de tiempo, el oyente no podrá detectar ninguna diferencia entre el audio original y el

audio marcado.

2.3.1 El Sistema Auditivo Humano y la Curva de Umbral Absoluto

El oído humano no es igualmente sensible a todas las frecuencias. La **curva de umbral absoluto de audición** (*Absolute Threshold of Hearing*, ATH) define la intensidad mínima (en dB SPL) que un sonido debe tener para ser audible en ausencia de otros sonidos, en función de la frecuencia. El oído humano es más sensible en la región de 1 a 4 kHz (donde la ATH alcanza valores mínimos de aproximadamente -5 dB SPL) y menos sensible a frecuencias muy bajas (por debajo de 100 Hz) y muy altas (por encima de 10 kHz). Esta curva ha sido modelada matemáticamente y es la base del diseño de codificadores de audio perceptual como MP3 y AAC.

2.3.2 Enmascaramiento en Frecuencia y Enmascaramiento Temporal

El fenómeno de **enmascaramiento** ocurre cuando un sonido fuerte (el *enmascarante*) hace que un sonido más débil (el *enmascarado*) se vuelva inaudible, aunque ambos sean perceptibles de forma aislada.

- **Enmascaramiento en frecuencia (*simultaneous masking*)**: Ocurre cuando el enmascarante y el enmascarado se presentan simultáneamente. Los sonidos con frecuencias cercanas al enmascarante son los más fácilmente enmascarados. El umbral de enmascaramiento se eleva en un rango de frecuencias alrededor del enmascarante, más pronunciado hacia frecuencias altas que hacia frecuencias bajas (efecto de asimetría del enmascaramiento).
- **Enmascaramiento temporal (*temporal masking*)**: El umbral de enmascaramiento no se resetea instantáneamente al desaparecer el enmascarante. El *pre-masking* ocurre hasta ~ 20 ms antes del enmascarante, y el *post-masking* puede durar hasta ~ 200 ms después. Durante el post-masking, un sonido débil sigue siendo inaudible incluso después de que el sonido fuerte haya cesado.

Los modelos psicoacústicos, como el definido en el estándar ISO/IEC 11172-3 (MPEG-1 Audio Layer III, también conocido como MP3), calculan los umbrales de enmascaramiento de forma dinámica para cada trama de audio. En sistemas de marcado de agua avanzados como *SilentCipher* [8], estos umbrales son calculados de forma diferenciable dentro del grafo de entrenamiento de la red neuronal, permitiendo que la función de pérdida penalice explícitamente

cualquier inserción de marca de agua que supere el umbral de enmascaramiento en cualquier frecuencia.

2.3.3 Bandas Críticas y la Escala Bark

La cóclea del oído interno actúa como un banco de filtros que descompone la señal de audio en componentes de frecuencia. Las **bandas críticas** (*critical bands*) modelan la resolución frecuencial del oído: dos sonidos en la misma banda crítica interactúan fuertemente (se enmascaran entre sí), mientras que sonidos en bandas críticas distintas apenas interactúan. El ancho de cada banda crítica es aproximadamente 100 Hz para frecuencias bajas y aumenta proporcionalmente para frecuencias altas. La escala **Bark** es una escala de frecuencia perceptual que divide el rango audible en 24 bandas críticas de ancho subjetivamente igual, y es utilizada en los modelos psicoacústicos para calcular los umbrales de enmascaramiento de forma más precisa que con la escala lineal o logarítmica.

2.4 Aprendizaje Profundo (Deep Learning)

El aprendizaje profundo es un subcampo del aprendizaje automático que utiliza redes neuronales artificiales con múltiples capas de procesamiento para extraer representaciones jerárquicas de los datos [11]. Cada capa transforma su entrada en una representación de mayor nivel de abstracción, permitiendo que el modelo aprenda a resolver tareas complejas directamente a partir de datos crudos, sin necesidad de un diseño manual de características.

2.4.1 El Perceptrón y la Neurona Artificial

La unidad básica de una red neuronal es la neurona artificial, inspirada en la neurona biológica. Formalmente, una neurona recibe un vector de entradas $\mathbf{x} \in \mathbb{R}^n$, computa una combinación lineal ponderada por un vector de pesos $\mathbf{w} \in \mathbb{R}^n$ y un sesgo b , y produce una salida mediante la aplicación de una función de activación σ :

$$y = \sigma(\mathbf{w}^T \mathbf{x} + b) \quad (7)$$

Las funciones de activación más comunes son:

- **ReLU (*Rectified Linear Unit*)**: $\sigma(z) = \max(0, z)$. Computacionalmente eficiente y evita el problema del gradiente que se desvanece (*vanishing gradient*) en capas profundas.

- **Sigmoid:** $\sigma(z) = 1/(1 + e^{-z})$. Produce salidas en el rango $(0, 1)$; útil en capas de salida para clasificación binaria.
- **Tanh:** $\sigma(z) = \tanh(z)$. Produce salidas en $(-1, 1)$; similar a sigmoid pero centrada en cero.
- **LeakyReLU:** $\sigma(z) = \max(\alpha z, z)$ con $\alpha \ll 1$. Mitiga el problema de neuronas muertas (*dying ReLU*) del ReLU estándar.

2.4.2 Entrenamiento: Descenso de Gradiente y Retropropagación

El entrenamiento de una red neuronal consiste en ajustar los parámetros $\theta = \{\mathbf{W}, \mathbf{b}\}$ de la red para minimizar una función de pérdida $\mathcal{L}(\theta)$ que mide el error entre las predicciones de la red y los valores esperados. El algoritmo estándar es el **descenso de gradiente estocástico (SGD)** y sus variantes (Adam, RMSProp), que actualiza los parámetros en la dirección opuesta al gradiente de la función de pérdida:

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} \mathcal{L}(\theta_t) \quad (8)$$

donde η es la tasa de aprendizaje (*learning rate*). El gradiente $\nabla_{\theta} \mathcal{L}$ se calcula de forma eficiente mediante el algoritmo de **retropropagación** (*backpropagation*), que aplica la regla de la cadena del cálculo diferencial para propagar el error desde la capa de salida hasta la capa de entrada a través de todas las capas intermedias.

2.4.3 Redes Neuronales Convolucionales (CNN)

Las Redes Neuronales Convolucionales (CNN, *Convolutional Neural Networks*) son la arquitectura predominante para el procesamiento de datos con estructura espacial o de rejilla, como imágenes y espectrogramas. Su componente central es la capa de convolución, que aplica un conjunto de filtros aprendibles $\mathbf{K} \in \mathbb{R}^{C_{in} \times k_h \times k_w}$ sobre la entrada mediante la operación de correlación cruzada:

$$(X * K)[i, j] = \sum_{c=1}^{C_{in}} \sum_{p=0}^{k_h-1} \sum_{q=0}^{k_w-1} X[c, i+p, j+q] \cdot K[c, p, q] \quad (9)$$

donde C_{in} es el número de canales de entrada, k_h y k_w son las dimensiones del filtro (típicamente 3×3 o 5×5), e (i, j) es la posición espacial de salida. Las capas convolucionales tienen tres propiedades clave que las hacen adecuadas para el procesamiento de señales:

- **Localidad:** Cada neurona de salida depende solo de una región local de la entrada (campo receptivo), lo que permite detectar patrones locales como bordes o texturas.
- **Compartición de parámetros:** El mismo filtro se aplica en todas las posiciones de la entrada, reduciendo drásticamente el número de parámetros entrenables.
- **Invariancia a la traslación:** Los patrones detectados por un filtro son detectados independientemente de su posición en la entrada, lo que es útil para reconocer estructuras de audio independientemente del instante temporal.

Además de las capas convolucionales, las CNN incluyen capas de **pooling** (que reducen la resolución espacial aumentando la invariancia y disminuyendo el costo computacional), **normalización por lotes** (*batch normalization*, que estabiliza el entrenamiento normalizando las activaciones por mini-lote), y capas de **dropout** (que desactivan aleatoriamente un porcentaje de neuronas durante el entrenamiento para prevenir el sobreajuste).

2.4.4 Autoencoders

Un Autoencoder es una arquitectura de red neuronal diseñada para aprender una representación comprimida (codificada) de los datos de entrada. Consta de dos subredes simétricas:

- **Codificador (*Encoder*):** Mapea la entrada $\mathbf{x} \in \mathbb{R}^D$ a una representación latente de menor dimensión $\mathbf{z} \in \mathbb{R}^d$, con $d \ll D$: $\mathbf{z} = f_\phi(\mathbf{x})$.
- **Decodificador (*Decoder*):** Reconstruye la entrada a partir de la representación latente: $\hat{\mathbf{x}} = g_\psi(\mathbf{z})$.

El entrenamiento minimiza una función de pérdida de reconstrucción, típicamente el error cuadrático medio (MSE): $\mathcal{L}_{rec} = \|\mathbf{x} - \hat{\mathbf{x}}\|_2^2$. En el contexto del marcado de agua, el Autoencoder se adapta para que el codificador reciba tanto la señal de audio como el mensaje a incrustar, y el decodificador actúe como extractor del mensaje a partir de la señal marcada (posiblemente degradada).

2.4.5 Arquitectura U-Net

La **U-Net** [12] es una variante del Autoencoder originalmente propuesta para segmentación de imágenes biomédicas, que ha demostrado ser altamente eficaz en tareas de procesamiento de señales. Su nombre proviene de la forma de “U” que adopta su diagrama de arquitectura.

La innovación principal de la U-Net respecto al Autoencoder estándar son las **conexiones de salto** (*skip connections*): en cada nivel de resolución, la salida de la capa del codificador correspondiente se concatena directamente con la entrada de la capa del decodificador del mismo nivel.

$$\hat{\mathbf{h}}_l = \text{Decode}([\mathbf{h}_l, \mathbf{z}_l]) \quad (10)$$

donde $[\cdot, \cdot]$ denota concatenación a lo largo de la dimensión de canales, $\mathbf{h}_l$ es la salida del codificador en el nivel l , y $\mathbf{z}_l$ es la representación del decodificador en el nivel l .

Las conexiones de salto permiten que los gradientes fluyan directamente desde la salida hasta las capas más tempranas del codificador, facilitando el entrenamiento de redes muy profundas. Más importante aún, permiten que el decodificador acceda a información de alta resolución que fue comprimida durante la fase de codificación, lo que resulta en una reconstrucción de mayor calidad. En el marcado de agua de audio, esta propiedad es crítica: los detalles espectrales finos del audio original deben preservarse en el audio marcado para garantizar la imperceptibilidad.

2.4.6 Redes Neuronales Invertibles (INN)

Las Redes Neuronales Invertibles (*Invertible Neural Networks*, INN) son un tipo especial de red neuronal donde la función implementada por la red es matemáticamente invertible por diseño. Esto significa que, dado un vector de salida $\mathbf{y}$, es posible calcular el vector de entrada $\mathbf{x} = f^{-1}(\mathbf{y})$ de forma exacta y eficiente. Las INN se implementan mediante bloques de acoplamiento (*coupling layers*), como los bloques de acoplamiento aditivo o afín de la arquitectura RealNVP. La invertibilidad garantiza que no haya pérdida de información durante la incrustación de la marca de agua, lo que se traduce en una alta fidelidad de reconstrucción del audio marcado. El sistema *WavMark* [5] y *IDEAW* [9] explotan esta propiedad.

2.5 Función de Pérdida en Sistemas de Marcado de Agua Profundo

El entrenamiento de un sistema de marcado de agua basado en aprendizaje profundo requiere una función de pérdida (*loss function*) que capture simultáneamente los objetivos de imperceptibilidad y robustez. La formulación más común, adoptada a partir de *HiDDeN* [4], es una combinación ponderada de dos términos:

$$\mathcal{L}_{total} = \lambda_{imp} \cdot \mathcal{L}_{imperceptibility} + \lambda_{rob} \cdot \mathcal{L}_{robustez} \quad (11)$$

donde:

- $\mathcal{L}_{imperceptibility} = \|x - \hat{x}\|_2^2$ es el error cuadrático medio entre la señal original y la señal marcada, que penaliza las diferencias perceptibles.
- $\mathcal{L}_{robustez} = \text{BCE}(D(A(\hat{x})), m)$ es la entropía cruzada binaria entre el mensaje recuperado y el mensaje original, que penaliza los errores de extracción.
- λ_{imp} y λ_{rob} son hiperparámetros que controlan el peso relativo de cada término.

Algunos sistemas más avanzados incluyen términos adicionales en la función de pérdida:

- **Pérdida perceptual (*perceptual loss*):** Calcula la diferencia entre las activaciones de una red preentrenada (e.g., VGGNet) al procesar el audio original y el audio marcado, capturando diferencias perceptuales de alto nivel que el MSE no detecta.
- **Pérdida psicoacústica:** Penaliza la perturbación introducida por la marca de agua cuando supera el umbral de enmascaramiento calculado por un modelo psicoacústico, como en *SilentCipher* [8].

2.6 Métricas de Evaluación

Para validar el desempeño del sistema, se emplean métricas objetivas que miden tanto la calidad perceptual del audio marcado como la confiabilidad de la extracción de la marca:

2.6.1 Relación Señal-Ruido (SNR)

La Relación Señal-Ruido (*Signal-to-Noise Ratio*, SNR) cuantifica la magnitud de la perturbación introducida por la marca de agua en la señal de audio:

$$\text{SNR} = 10 \log_{10} \frac{\sum_{n=1}^T x[n]^2}{\sum_{n=1}^T (x[n] - \hat{x}[n])^2} \quad [\text{dB}] \quad (12)$$

Un valor alto de SNR indica que la perturbación es pequeña en relación con la señal original. En general, valores de SNR superiores a 30 dB se consideran indicativos de buena imperceptibilidad, aunque este umbral depende del tipo de señal y del contexto de escucha.

2.6.2 Tasa de Error de Bit (BER)

La Tasa de Error de Bit (*Bit Error Rate*, BER) mide la proporción de bits del mensaje que son recuperados incorrectamente por el extractor:

$$\text{BER} = \frac{1}{L} \sum_{i=1}^L \mathbf{1}[\hat{m}_i \neq m_i] \quad (13)$$

donde L es el número de bits del mensaje, m_i es el bit original y $\hat{m}_i$ es el bit recuperado. Una BER de 0% indica una extracción perfecta, mientras que una BER de 50% es equivalente a una extracción aleatoria (el extractor no provee ninguna información útil). En la práctica, se considera que un sistema es funcional cuando su BER es inferior al 5% bajo los ataques evaluados.

2.6.3 Grado de Distorsión Objetiva (ODG) y PEAQ

El Grado de Distorsión Objetiva (*Objective Difference Grade*, ODG) es una métrica perceptual basada en el estándar ITU-R BS.1387, implementada mediante el algoritmo *PEAQ* (*Perceptual Evaluation of Audio Quality*). PEAQ modela el sistema auditivo humano para calcular, de forma automatizada, cuál sería la calificación que un oyente humano daría a la diferencia entre el audio original y el audio marcado, en una escala de 0 (sin diferencia perceptible) a -4 (muy molesto). La ventaja de ODG sobre el SNR es que incorpora el modelo psicoacústico del sistema auditivo, siendo más correlacionado con la percepción real del oyente.

2.6.4 Precisión de Detección (para sistemas de detección binaria)

En sistemas como *AudioSeal* [7], donde el objetivo es detectar si un fragmento de audio ha sido marcado (y no recuperar un mensaje), la métrica principal es la precisión de detección (*detection accuracy*), definida como la proporción de fragmentos correctamente clasificados como marcados o no marcados. Se complementa con la tasa de falsos positivos (clasificar como marcado un audio no marcado) y la tasa de falsos negativos (no detectar la marca en un audio que sí la contiene).

3 Metodología

La metodología de este proyecto se divide en etapas secuenciales que permiten transformar las señales de audio originales en datos aptos para el entrenamiento y evaluación de modelos de aprendizaje profundo. Cada etapa está diseñada para garantizar la integridad de los datos y la robustez del sistema de marcado de agua.

3.1 Etapa 1: Segmentación del Audio (Preprocesamiento)

Debido a que las redes neuronales profundas requieren tensores de entrada con dimensiones fijas, la primera etapa consiste en una segmentación uniforme de los archivos de audio originales.

- **Procedimiento:** Se cargan los archivos de audio utilizando la librería *librosa*, ampliamente utilizada en el análisis de audio computacional. Cada señal se divide en fragmentos de duración objetivo $t_{target} = 5$ segundos.
- **Criterio de Descarte:** Para evitar el uso de técnicas de relleno (*padding*) que podrían inducir sesgos, se implementó un criterio estricto donde cualquier residuo final de la señal que no complete los 5 segundos es ignorado.
- **Métricas de Amplitud:** Durante este proceso se registran las amplitudes máximas y mínimas de cada canal (izquierdo y derecho) para detectar posibles recortes (*clipping*) y analizar el rango dinámico, lo cual es vital para determinar la ganancia de inserción de la marca de agua.

3.2 Etapa 2: Procesamiento por Bloques (Framing) y Solapamiento (Overlap)

Para analizar la señal bajo la suposición de que es cuasi-estacionaria, se aplica una técnica de segmentación en bloques de corta duración.

- **Configuración:** Se definieron bloques de $N = 512$ muestras. A una frecuencia de muestreo de 44100 Hz, esto equivale a aproximadamente 11.6 ms, tiempo suficiente para asumir estabilidad acústica.
- **Solapamiento:** Se utiliza un salto de $H = 256$ muestras, lo que resulta en un solapamiento (*overlap*) del 50%.

- **Importancia:** El solapamiento es crucial para evitar la pérdida de información en los bordes de los bloques tras la aplicación de funciones de ventana (como Hamming o Hann) y para garantizar una reconstrucción suave de la señal (*Constant Overlap-Add*, COLA) tras el proceso de marcado.

3.3 Etapa 3: Diseño e Implementación de la Red Neuronal Profunda

En esta fase se diseña la arquitectura del modelo que realizará la inserción y extracción de la marca de agua.

- **Arquitectura:** Se exploran modelos basados en Autoencoders convolucionales y U-Net, que han demostrado alta eficacia en tareas de procesamiento de audio y restauración de señales.
- **Dominio de Operación:** El modelo opera predominantemente en el dominio espectral (mediante la STFT) para aprovechar las propiedades psicoacústicas del oído humano, permitiendo que la marca de agua se oculte en frecuencias donde es menos perceptible pero más robusta.
- **Entrenamiento:** Se incorpora una capa de ruido simulado durante el entrenamiento para forzar al modelo a aprender representaciones robustas frente a ataques como la compresión MP3 y el ruido blanco.




Figura 1: Diagrama de flujo del proceso de preprocesamiento y marcado de audio.

4 Resultados

Este apartado es lo más importante de tu reporte. En el debes describir a detalle (texto) y en apoyo en gráficas, tablas, fragmentos de códigos, diagramas e imágenes de los resultados obtenidos, tales como: reducción de costos, mejoras en líneas de producción, optimizaciones de procesos, diseños funcionales, implementaciones físicas, manuales actualizados, campañas de márketing, estudios de mercado, manuales de procesos, software, base de datos entre otros. Sus características son:

- Se presentan de manera clara y son reflejo de las actividades realizadas.
- Están ligados a las etapas de desarrollo (dependiendo el número de etapas de desarrollo, son él número de resultados).
- Se demuestra el cumplimiento de los objetivos operacionales propuestos.
- Puedes utilizar gráficas, tablas, esquemas que mejoren la explicación.
- Se describen los beneficios generados.
- Sin límite de extensión.

De

5 Conclusiones

Incluye:

- Resultados relevantes.
- Experiencia personal y profesional.
- Sugerencias de mejora.

Referencias

- [1] Ingemar Cox et al. «Digital watermarking and steganography». En: (2007).
- [2] Michael Arnold. «Audio watermarking: Features, applications and algorithms». En: *2000 IEEE International Conference on Multimedia and Expo. ICME 2000. Proceedings. Latest Advances in the Fast Changing World of Multimedia (Cat. No. 00TH8532)*. Vol. 2. IEEE. 2000, págs. 1013-1016.
- [3] Laurence Boney, Ahmed H Tewfik y Khaled N Hamdy. «Digital watermarks for audio signals». En: *Proceedings of the third IEEE international conference on multimedia computing and systems*. IEEE. 1996, págs. 473-480.
- [4] Jiren Zhu et al. «Hidden: Hiding data with deep networks». En: *Proceedings of the European conference on computer vision (ECCV)*. 2018, págs. 657-672.
- [5] Guangyu Chen et al. «WavMark: Watermarking for Audio Generation». En: *arXiv preprint arXiv:2308.12770* (2023).
- [6] Chang Liu et al. «DeAR: A Deep-learning-based Audio Re-recording Resilient Watermarking». En: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 37. 11. 2023, págs. 13201-13209.
- [7] Robin San Roman et al. «Proactive Detection of Voice Cloning with Localized Watermarking». En: *International Conference on Machine Learning (ICML)*. 2024.
- [8] Mayank Kumar Singh et al. «SilentCipher: Deep Audio Watermarking». En: *arXiv preprint arXiv:2406.03822* (2024).
- [9] Pengcheng Li et al. «IDEAW: Robust Neural Audio Watermarking with Invertible Dual-Embedding». En: *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. 2024, págs. 4500-4511.
- [10] Hongbin Liu, Moyang Guo, Jun Li et al. «AudioMarkBench: Benchmarking Robustness of Audio Watermarking». En: *arXiv preprint arXiv:2406.06979* (2024).
- [11] Ian Goodfellow, Yoshua Bengio y Aaron Courville. *Deep learning*. MIT press, 2016.
- [12] Olaf Ronneberger, Philipp Fischer y Thomas Brox. «U-net: Convolutional networks for biomedical image segmentation». En: (2015), págs. 234-241.

Instituto Mexicano del Seguro Social

Constancia de Vigencia de Derechos

Homoclave del trámite	Homoclave del formato	Fecha de publicación del formato en el DOF
IMSS-02-020	FF-IMSS-012	10 / 11 / 2015 DD MM AAAA

Datos Generales

NSS:	52230538762
CURP:	RABO050813HTSMLSA4
Nombre(s), primer apellido y segundo apellido:	OSVALDO FABIAN RAMIRO BALBOA
Sexo:	Hombre
Fecha de nacimiento:	13/08/2005
Lugar de nacimiento:	TAMAULIPAS

Datos de Aseguramiento

Con derecho al servicio médico:	SI
Vigente:	11/02/2026
Delegación:	TAMAULIPAS
UMF:	UMF 067 SAN LUISITO
Turno:	VESPERTINO
Consultorio:	CONSULTORIO 4
Agregado Médico:	1M2005ES

Datos de Aseguramiento

Registro Patronal	Nombre o razón social
F0543370327	UNIVERSIDAD POLITECNICA DE VICTORIA
Modalidad de Aseguramiento	Descripción de Modalidad
MODALIDAD 32	SEGURO FACULTATIVO ESTUDIANTES

Detalle de vigencia

Estado	Inicio de Vigencia	Fecha de Constancia
VIGENTE	09/02/2026	11/02/2026

Beneficiarios

NO APLICA

"De conformidad con los artículos 4 y 69-M, fracción V de la Ley Federal de Procedimiento Administrativo, los formatos para solicitar trámites y servicios deberán publicarse en el Diario Oficial de la Federación (DOF)"

**GOBIERNO DE
MÉXICO****Contacto**

Paseo de la Reforma 476, P.B.
Col. Juárez, Alcaldía Cuauhtémoc
C.P. 06600, Ciudad de México.
Tel. 800 623 23 23
<http://www.imss.gob.mx/contacto>

Ciudad Victoria,
Tamaulipas, a 01
de Mayo
de 2026

**CENTRO DE INVESTIGACIÓN Y ESTUDIOS AVANZADOS DEL INSTITUTO
POLITÉCNICO NACIONAL (CINVESTAV TAMAULIPAS)
DR. JOSÉ JUAN GARCÍA HERNÁNDEZ
PRESENTE**

La Universidad Politécnica de Victoria tiene a bien presentar a **RAMIRO BALBOA OSVALDO FABIAN** estudiante del programa académico de **INGENIERÍA EN TECNOLOGÍAS DE LA INFORMACIÓN E INNOVACIÓN DIGITAL** en su modalidad de **DESARROLLO DE SOFTWARE MULTIPLATAFORMA**, con número de matrícula **2430098** y seguro facultativo IMSS número **52230538762**; quien deberá realizar su práctica profesional de **ESTADÍA TSU**, a partir del 04 de Mayo de 2026 al 14 de Agosto de 2026, con duración de **600 horas** desarrollando el proyecto "**MARCAO DE AGUA DIGITAL PROFUNDO Y ROBUSTO EN SEÑALES DE AUDIO.**" que le fue asignado.

Al concluir se le extenderá la carta de liberación al evaluarlo satisfactoriamente y además le solicitaremos su valiosa opinión respondiendo el formulario que se le enviará por correo electrónico, referente al desempeño del practicante, la información que nos proporcione es de vital importancia para la mejora de los programas académicos que ofrece la Universidad Politécnica de Victoria para la formación de profesionistas altamente especializados.


El practicante deberá cumplir con el Reglamento Interno aplicable al personal en su centro de trabajo.

Sin otro particular.

ATENTAMENTE



**OTHÓN CANO GARZA
DIRECTOR DE VINCULACIÓN**



UNIVERSIDAD POLITÉCNICA DE VICTORIA

Av. Nuevas Tecnologías 5902
Parque Científico y Tecnológico de Tamaulipas
Carretera Victoria-Soto La Marina Km. 5.5
Cd. Victoria, Tamaulipas. C.P. 87138

Tel: (834) 1711000 al 10
www.upvictoria.edu.mx



"2026, Año de Margarita Maza Parada"

Cd. Victoria, Tamaulipas, a 6 de mayo del 2026.
UT/CA/060526/069
Asunto: Carta de aceptación a Estadía.

M. A. Othon Cano Garza
Director de Vinculación
Universidad Politécnica de Victoria
Presente,

Por este medio le comunico que el alumno Osvaldo Fabian Ramiro Balboa, de la carrera de Ingeniería en Tecnologías de la Información e Innovación Digital de la Universidad Politécnica de Victoria con número de control 2430098, ha sido ACEPTADO para realizar su Estadía TSU en el Centro de Investigación y de Estudios Avanzados del Instituto Politécnico Nacional (Cinvestav) Unidad Tamaulipas con sede en Ciudad Victoria; comprendido del 4 de mayo al 14 de agosto 2026.

El C. Osvaldo Fabian Ramiro Balboa estará vinculado directamente a las actividades del proyecto de investigación titulado "Marcado de agua digital profundo y robusto en señales de audio", bajo la dirección del Dr. José Juan García Hernández.

Al concluir las actividades de estadía y a petición del profesor anfitrión, el Cinvestav Unidad Tamaulipas entregará la carta de liberación de Estadía TSU del alumno únicamente a través del mecanismo institucional de la Universidad Politécnica de Victoria que tenga a bien indicarnos, por ejemplo: departamento de servicios escolares, departamento de vinculación, responsable del programa académico.

Sin otro particular, me despido de usted enviándole un cordial saludo.

Atentamente



Dr. José Gabriel Ramírez Torres
Coordinador Académico de la Unidad Tamaulipas

Ing. Juan Camaney de Alba Rojas
PRESENTE

INSERTAR AQUÍ
DOCUMENTO
DE CARTA
DE LIBERACION
DEBIDAMENTE
FIRMADO

Rúbrica para la Evaluación del Reporte de Estadía

Nombre completo del estudiante: Oswaldo Fabian Ramiro Balboa Matrícula: 2430098 PERIODO: Mayo-Agosto 2026 Nombre del evaluador: Dr. Said Polanco Martagón			
Firma del Evaluador: _____ Calificación Final: ____ / 100			
Valor	Características a cumplir	Puntos	Observaciones
6	Resumen ejecutivo y abstract: Indica qué se realizó, cómo se realizó y qué se obtuvo. (una cuartilla en español e inglés)		
6	Contenido temático: Describe correctamente el contenido del documento		
6	Introducción: El informe cumple con introducir al lector de una manera atractiva el panorama general del trabajo realizado en la unidad económica.		
6	Descripción de la unidad económica: Se redactan los detalles de los antecedentes del departamento, la empresa, giro, misión, visión, infraestructura, ubicación.		
6	Objetivos operativos: Describen las acciones a cumplir mediante actividades establecidas por el asesor empresarial		
24	Metodología: Descripción a detalle de las etapas y procedimientos utilizados en el proyecto		
18	Resultados: Interpreta y analiza los resultados obtenidos durante su estadía.		
12	Conclusiones: Las conclusiones son claras y acordes con el objetivo esperado		
6	Bibliografía y anexos: Cita correctamente las fuentes de información utilizando un estilo de referencia; anexa cartas correspondientes		
10	Responsabilidad: Entregó el reporte en la fecha y hora señalada. Asistió al menos al 80% de sus días de Estadía		

Rúbrica para Exposición del Reporte de Estadía

Criterio	Nivel de logro		
	Bueno (10%)	Regular (7%)	Menor a lo esperado (5%)
Dominio del tema (10%)	Utiliza todos los términos y conceptos de manera correcta.	Utiliza la mayoría términos y conceptos de manera correcta	Confunde los términos y conceptos.
Presentación de material visual (10%)	Las diapositivas usadas tienen fondo claro, letras, tablas e imágenes visibles. La presentación contiene los aspectos relevantes de la Estadía	Las diapositivas usadas presentan dificultad para su apreciación visual. La presentación contiene los aspectos relevantes de la Estadía	Las diapositivas usadas presentan dificultad para su apreciación visual. La presentación carece de algunos aspectos relevantes de la Estadía.
Comunicación y expresión (10%)	Su volumen de voz es comprensible. Su expresión corporal manifiesta seguridad ejecutiva. Su atuendo cumple los estándares de ser formal o semiformal. Mantiene una línea de respeto en general.	Su volumen de voz no es comprensible. Su expresión corporal manifiesta inseguridad. Su atuendo cumple los estándares de ser formal o semiformal. Mantiene una línea de respeto en general.	Su volumen de voz no es comprensible. Su expresión corporal manifiesta inseguridad. Su atuendo no cumple los estándares de ser formal o semiformal. Realiza alguna falta de respeto.
Respuestas (10%)	Las respuestas son consistentes y con parámetros de lógica operativa.	Las respuestas no son consistentes pero tienen parámetros de lógica operativa.	Las respuestas son difusas e incoherentes.
Ponderación final de su exposición:		___ /100	
Día / Mes / Año		12/ Agosto/ 2026	
Comentario adicional			